




Chương 1

Tổng quan về lưu trữ và xử lý dữ liệu lớn

ONE LOVE. ONE FUTURE.

Hình dung về độ lớn của dữ liệu



Nói về dữ liệu lớn năm 2014



THE AVERAGE PERSON TODAY PROCESSES MORE DATA IN A SINGLE DAY THAN A PERSON IN THE 1500'S DID IN AN ENTIRE LIFETIME ▼

LOOK TO THE LEFT, and you see Times Square at dusk. Look to the right, and you see the same location at midmorning. Internationally acclaimed photographer Stephen Wilkes's time-altering image of New York's Times Square is part of his body of work titled *Day to Night*.

The image was created by blending more than 1,400 separate photos taken over the course of 15 hours—a meticulous process that took him nearly three months.

PHOTO: STEPHEN WILKES


Những con số về tốc độ sinh dữ liệu

2020 *This Is What Happens In An Internet Minute*



Các nguồn tạo ra dữ liệu lớn


- Thương mại điện tử
- Mạng xã hội
- Internet vạn vật (IoT)
- Các thử nghiệm dữ liệu lớn (tin sinh học, vật lý lượng tử, vvv)



Dữ liệu được ví như nguồn tài nguyên dầu mỏ mới




Đặc điểm 5'V của dữ liệu lớn



Dữ liệu lớn là tập dữ liệu quá lớn hoặc là quá phức tạp mà các nền tảng lưu trữ và xử lý dữ liệu truyền thống không đáp ứng được.

Dữ liệu lớn – giá trị mang lại lớn



Amazon

Amazon thu thập dữ liệu về mọi khách hàng của họ trong khi khách hàng bắt đầu hành trình sử dụng trang web. Một số yếu tố điển hình từ một khách hàng Amazon thu thập như: sản phẩm bạn đã mua (thậm chí cả những sản phẩm bạn cân nhắc), địa chỉ giao hàng (Amazon dựa vào vị trí địa lý để đưa ra dự đoán mức thu nhập của khách hàng) và tất nhiên cả những đánh giá và phản hồi của bạn tại website.

Lượng dữ liệu khổng lồ này được Amazon sử dụng để xây dựng một góc nhìn tổng thể 360 độ của một cá nhân khách hàng. Amazon sau đó có thể nhóm chung các khách hàng cá nhân này thành một nhóm có chung đặc điểm (Ví dụ: bạn giới tính nam, từ 18 đến 45 tuổi, sống trong một ngôi nhà thuê với thu nhập trên 30.000 đô la, và có sở thích xem phim nước ngoài) để từ đó đưa ra những khuyến nghị gần nhất với nhu cầu của nhóm khách hàng đó

<https://bernardmarr.com/amazon-using-big-data-to-understand-customers/>
<https://ocd.vn/amazon-da-ung-dung-big-data-de-hieu-khach-hang-nhu-the-nao/>


Let's talk with numbers

How a product recommendation engine can boost your revenue

Amazon's sales



Rolls Royce




Bigdata hỗ trợ trong Design - Manufacture - After-Sale Support

<https://www.forbes.com/sites/bernardmarr/2015/06/01/how-big-data-drives-success-at-rolls-royce/#43e6a4331d69>

TikTok

- TikTok has 1.04 billion monthly active users globally as of 2024.
- TikTok users spend 58 minutes and 24 seconds on the app daily as of 2024.
- The majority of TikTok users are between the ages of 18 to 34, at 69.3%.



Khai thác dữ liệu lớn trong giáo dục



Khai thác dữ liệu lớn trong khoa học chăm sóc sức khỏe

- Giảm chi phí điều trị, các xét nghiệm dư thừa
- Dự đoán quy mô đại dịch, khuyến nghị các biện pháp ứng phó
- Ngăn ngừa sớm các bệnh có thể gặp trong tương lai




Khai thác dữ liệu lớn trong quản lý nhà nước

- Các chương trình phúc lợi xã hội
 - Nắm bắt nhanh chóng các vấn đề xã hội (việc làm, tội phạm, môi trường, vvv)
 - Khuyến nghị các biện pháp đối phó
- An ninh thông tin
 - Trốn thuế
 - Lừa đảo



The world is running out of data to train AI

LARGE LANGUAGE MODEL HIGHLIGHTS (FEB/2024)




Sizes linear to scale. Selected highlights only. All models are available. All models are Chinchilla-aligned (20:1 tokens:parameters) <https://lilearchitect.ai/chinchilla/> All 200+ models: <https://lilearchitect.ai/models-table/> Alan D. Thompson. 2023-2024.



LifeArchitect.ai/models

10 công ty lớn nhất (1998-2018)


Market Capitalization in Billions USD




<https://www.youtube.com/watch?v=fobx4wIS6W0>

10 công ty lớn nhất (1998-2018)

Market Capitalization in Billions USD



Các tầng công nghệ cho dữ liệu lớn



Quản lý dữ liệu phải khả mở

- Scalability
 - Khả năng quản lý lượng dữ liệu lớn không ngừng tăng lên theo thời gian.
- Accessibility
 - Cho phép đọc ghi I/O dữ liệu hiệu quả.
- Transparency
 - Truy cập dữ liệu dễ dàng, vị trí lưu trữ dữ liệu trên hệ thống là trong suốt với người dùng cuối.
- Availability
 - Khả năng chống chịu lỗi, khi tăng số lượng người dùng, khi hỏng hóc.

Xử lý và tích hợp dữ liệu phải khả mở


- Tích hợp dữ liệu
 - Dữ liệu có định dạng khác nhau
 - Dữ liệu tồn tại ở các mô hình và lược đồ dữ liệu khác nhau
 - Các vấn đề liên quan đến an toàn an ninh thông tin, quyền riêng tư
- Xử lý dữ liệu
 - Xử lý khối lượng dữ liệu rất lớn
 - Xử lý luồng dữ liệu lớn
 - Xử lý dữ liệu song song, phân tán truyền thống (OpenMP, MPI)
 - Phức tạp, khó học
 - Khả năng khả mở có giới hạn
 - Cơ chế chịu lỗi kém
 - Chi phí hạ tầng đắt đỏ
 - Kiến trúc xử lý dữ liệu luồng dữ liệu lớn
 - Spark mini-batch
 - Apache Flink

Các giải thuật phân tích dữ liệu khả mở

- Làm nhỏ lại dữ liệu cho phù hợp với các giải thuật truyền thống
 - Eg. Sub-sampling
 - Eg. Principal component analysis
 - Eg. Feature extraction and feature selection
- Song song hoá các giải thuật học máy
 - Eg. k-nn classification based on MapReduce
 - Eg. scaling-up support vector machines (SVM) by a divide and-conquer approach




Eg. Sự bùng nổ số chiều trong dữ liệu (Curse of dimensionality)

- Số lượng mẫu cần cho mô hình học tăng lên khi số chiều dữ liệu tăng
- Trong thực tiễn: Số lượng mẫu để học thường cố định
 - => Độ chính xác của mô hình giảm khi tăng số chiều trong dữ liệu học



Sử dụng và trực quan hoá dữ liệu lớn

- Cần kiến thức chuyên gia
- Cần kỹ thuật và công cụ để hỗ trợ hiệu quả việc trình diễn và hiểu về dữ liệu lớn



Bảo mật và quyền riêng tư

Khoa học công nghệ > Chuyển đổi số


Thứ bảy, 13/7/2019, 08:50 (GMT+7)

Facebook nhận khoản phạt kỷ lục 5 tỷ USD

Mức 5 tỷ USD (khoảng 116,3 nghìn tỷ đồng) là khoản phạt lớn nhất mà Mỹ áp với một công ty công nghệ do vi phạm quyền riêng tư.

Facebook Users' Privacy Concerns

marketing charts



Published on MarketingCharts.com in April 2018 | Data Source: Gallup

Based on telephone interviews conducted April 2-8, 2018 among 1,509 US adults ages 18 and older, of whom 785 are Facebook users. The remaining respondents answered "Not too concerned" or "Not concerned at all."

How was Facebook users' data misused?


- 1** In 2014 a Facebook quiz invited users to find out their personality type
- 2** The app collected the data of those taking the quiz, but also recorded the public data of their friends
- 3** About 305,000 people installed the app, but it gathered information on up to 87 million people, according to Facebook
- 4** It is claimed at least some of the data was sold to Cambridge Analytica (CA) which used it to psychologically profile voters in the US
- 5** CA denies it broke any laws and says it did not use the data in the US presidential election
- 6** Facebook sends notices to users telling them whether their data was breached

CA denies any wrongdoing. Facebook has apologised to users and says a "breach of trust" has occurred.

Thiếu hụt nhân lực liên quan tới dữ liệu lớn


MỨC LƯƠNG LẬP TRÌNH VIÊN THEO VỊ TRÍ TRONG NGÀNH

[Đơn vị: USD]
Lưu ý: Tất cả dữ liệu tiền lương được nêu trong trang này đề cập đến tổng tiền lương hàng tháng trước thuế và không bao gồm các phúc lợi khác như làm thêm giờ, tiền thưởng, v.v.




<https://topdev.vn/blog/big-data-can-hoc-gi/>

Nhóm các kỹ năng cần thiết theo vị trí




Gợi ý tìm hiểu về dữ liệu lớn


- Học lập trình
 - Coursera
 - Udacity
 - Freecodecamp
 - Codecademy
- Học học máy, toán, toán thống kê
- Kaggle
- Hadoop, NoSQL, Spark
- Các công cụ báo cáo và trực quan hoá
 - Tableau
 - Pentahoo
- Gặp gỡ và chia sẻ
- Tìm cổ vấn
- Thực tập, dự án



Quy trình làm khoa học dữ liệu



- Chiếm khoảng 80% các công việc của nhà khoa học dữ liệu




What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

source: <https://www.forbes.com/>

- 57% các nhà khoa học dữ liệu cho rằng đây là công việc kém thú vị



What's the least enjoyable part of data science?

- Building training sets: 10%
- Cleaning and organizing data: 57%
- Collecting data sets: 21%
- Mining data for patterns: 3%
- Refining algorithms: 4%
- Other: 5%

Tài liệu tham khảo

- [1] Tiwari, Shashank. Professional NoSQL. John Wiley & Sons, 2011.
- [2] Lam, Chuck. Hadoop in action. Manning Publications Co., 2010.
- [3] Miner, Donald, and Adam Shook. MapReduce design patterns: building effective algorithms and analytics for Hadoop and other systems. " O'Reilly Media, Inc.", 2012.
- [4] Karau, Holden. Fast Data Processing with Spark. Packt Publishing Ltd, 2013.
- [5] Penchikala, Srin. Big data processing with apache spark. Lulu. com, 2018.
- [6] White, Tom. Hadoop: The definitive guide. " O'Reilly Media, Inc.", 2012.
- [7] Gandomi, Amir, and Murtaza Haider. "Beyond the hype: Big data concepts, methods, and analytics." International Journal of Information Management 35.2 (2015): 137-144.
- [8] Cattell, Rick. "Scalable SQL and NoSQL data stores." Acm Sigmod Record 39.4 (2011): 12-27.
- [9] Gessert, Felix, et al. "NoSQL database systems: a survey and decision guidance." Computer Science-Research and Development 32.3-4 (2017): 353-365.
- [10] George, Lars. HBase: the definitive guide: random access to your planet-size data. " O'Reilly Media, Inc.", 2011.
- [11] Sivasubramanian, Swaminathan. "Amazon dynamoDB: a seamlessly scalable non-relational database service." Proceedings of the 2012 ACM SIGMOD International Conference on Management of Data. ACM, 2012.
- [12] Chan, L. "Presto: Interacting with petabytes of data at Facebook." (2013).
- [13] Garg, Nishant. Apache Kafka. Packt Publishing Ltd, 2013.
- [14] Karau, Holden, et al. Learning spark: lightning-fast big data analysis. " O'Reilly Media, Inc.", 2015.
- [15] Iqbal, Muhammad Hussain, and Tariq Rahim Soomro. "Big data analysis: Apache storm perspective." International journal of computer trends and technology 19.1 (2015): 9-14.
- [16] Toshniwal, Ankit, et al. "Storm@ twitter." Proceedings of the 2014 ACM SIGMOD international conference on Management of data. ACM, 2014.
- [17] Lin, Jimmy. "The lambda and the kappa." IEEE Internet Computing 21.5 (2017): 60-66.

Các khoá học trực tuyến

- <https://www.coursera.org/learn/nosql-database-systems>
- <https://who.rocq.inria.fr/Vassilis.Christophides/Big/index.htm>
- <https://www.coursera.org/learn/big-data-introduction?specialization=big-data>
- <https://www.coursera.org/learn/big-data-integration-processing?specialization=big-data>
- <https://www.coursera.org/learn/big-data-management?specialization=big-data>
- <https://www.coursera.org/learn/hadoop>
- <https://www.coursera.org/learn/scala-spark-big-data>