

L02 - Tài liệu hướng dẫn thực hành với Hadoop

06/2025

Mục lục

Phần 1: Giới thiệu.....	1
1.1 Mục đích và ý nghĩa tài liệu.....	1
1.2 Yêu cầu chuẩn bị.....	1
Phần 2: Chuẩn bị các công cụ cần thiết.....	2
2.1 Git.....	2
2.2 Terraform.....	2
2.3 gcloud.....	2
2.4 Ansible.....	4
Phần 3: Cài cụm Hadoop.....	5
Phần 4: Thực hành sử dụng với HDFS và Yarn.....	9
4.1 Đẩy file dữ liệu vào HDFS.....	9
4.2 Chạy chương trình xử lý dữ liệu trong HDFS.....	10
Phần 5: Kết thúc.....	12

Phần 1: Giới thiệu

1.1 Mục đích và ý nghĩa tài liệu

Tài liệu này hướng dẫn người dùng cài đặt cụm Hadoop lên các VM trên Google Cloud.

1.2 Yêu cầu chuẩn bị

- Một máy tính (Laptop, PC) có kết nối internet.
- Một tài khoản Google Cloud
- Ứng dụng VSCode

Phần 2: Chuẩn bị các công cụ cần thiết

Trong bài thực hành này, chúng ta sử dụng các công cụ để giúp tự động hoá việc cài đặt cụm Hadoop. Điều này đòi hỏi chúng ta phải cài đặt một số phần mềm như sau:

- **Git**: công cụ quản lý mã nguồn. Ngoài ra, đối với các máy tính Windows chúng ta nên sử dụng Git Bash terminal để thực hiện các câu lệnh trong bài này.
- **Terraform**: Infrastructure as code (IaC tools) – Sử dụng để tạo dựng các VM trên Google Cloud Platform (GCP).
- **gcloud**: Công cụ terminal của GCP có rất nhiều tính năng, tuy nhiên trong bài thực hành này, gcloud dùng để đăng nhập vào GCP, từ đó Terraform cho phép Terraform xác thực khi gọi tới GCP.
- **Ansible**: Configuration as code – Sử dụng để tự động hoá thực hiện các lệnh trên các VM.

2.1 Git

Vui lòng tham khảo tại: <https://git-scm.com/downloads>

2.2 Terraform

Vui lòng tham khảo tại:

<https://developer.hashicorp.com/terraform/tutorials/aws-get-started/install-cli>

Kiểm tra việc cài đặt đã thành công bằng lệnh:

```
terraform -v
```


2.3 gcloud

Vui lòng tham khảo tại: <https://cloud.google.com/sdk/docs/install>


Sau khi cài đặt thành công, thực hiện lệnh sau để đăng nhập vào GCP:

```
gcloud auth application-default login
```

Một cửa sổ trình duyệt sẽ được hiện thị ra để người dùng đăng nhập:



Đây là màn hình sau khi đăng nhập thành công:



2.4 Ansible

Vui lòng tham khảo tại:

https://docs.ansible.com/ansible/latest/installation_guide/intro_installation.html

Kiểm tra việc cài đặt thành công bằng lệnh sau:

```
ansible --version
```

Phần 3: Cài cụm Hadoop

Bước 1: Clone code từ repo: <https://github.com/BKCLab/bigdata-learning.git>

```
git clone https://github.com/BKCLab/bigdata-learning.git
```

Bước 2: Mở thư mục “l2/hadoop-cluster” bằng VSCode


```
cd bigdata-learning/l2/hadoop-cluster
```

Bước 3:


Mở thư mục con “terraform”, tạo một file có tên “terraform.tfvars” với nội dung thay bằng giá trị của riêng bạn, ví dụ như sau:

```
project_id    = "bigdata-learning-463402"
ssh_pubkey_path = "~/ssh/id_rsa.pub"
```

Dưới đây là ảnh minh họa:



*Trong đó: **project_id** là mã dự án trên GCP*



ssh_pubkey_path là đường dẫn tới file public key của cặp khoá ssh, nếu chưa có bạn có thể sinh cặp khoá bằng câu lệnh:

```
ssh-keygen -t rsa -b 4096
```

Bước 4: Sửa permission cho file script:

```
chmod +x up.sh
chmod +x destroy.sh
```

Bước 5: Chạy script tạo dựng hệ thống:

```
./up.sh
```

Chờ và quan sát các bước đang được thực hiện.

Sau khi đoạn mã thực hiện xong (khoảng 5-10p), có thể truy cập hệ thống HDFS theo đường link hiển thị ra: `http://<namenode-ip>:9870`

Bước 6: Truy cập UI của HDFS:

Nếu truy cập vào đường link và có hiển thị trang web này thì có nghĩa là HDFS đã chạy:

Namenode information

All Applications

Not Secure

34.101.41.119:9870/dfshealth.html#tab-overview

Finish update

Hadoop

Overview

Datanodes

Datanode Volume Failures

Snapshot

Startup Progress

Utilities

Overview

'namenode:9000' (active)

Started:	Fri Jun 27 09:20:19 +0700 2025
Version:	3.3.6, r1be78238728da9266a4f88195058f08fd012bf9c
Compiled:	Sun Jun 18 15:22:00 +0700 2023 by ubuntu from (HEAD detached at release-3.3.6-RC1)
Cluster ID:	CID-d46e9d46-22eb-470d-b088-97f0c2ed7ed3
Block Pool ID:	BP-653596245-34.101.41.119-1750990810772

Summary

Security is off.

Safemode is off.

1 files and directories, 0 blocks (0 replicated blocks, 0 erasure coded block groups) = 1 total filesystem object(s).

Heap Memory used 109.78 MB of 283 MB Heap Memory. Max Heap Memory is 1.94 GB.

Non Heap Memory used 55.43 MB of 58.19 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	38.4 GB
Configured Remote Capacity:	0 B
DFS Used:	56 KB (0%)
Non DFS Used:	10.32 GB
DFS Remaining:	28.06 GB (73.05%)
Block Pool Used:	56 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	2 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)

Xem danh sách các datanode: (cụm chúng ta có 1 namenode và 2 datanodes)

Namenode information

All Applications

Not Secure

34.101.41.119:9870/dfshealth.html#tab-datanode

Finish update

Hadoop

Overview

Datanodes

Datanode Volume Failures

Snapshot

Startup Progress

Utilities

Datanode Information

In service

Down

Decommissioning

Decommissioned

Decommissioned & dead

Entering Maintenance

In Maintenance

In Maintenance & dead

Datanode usage histogram

Disk usage of each DataNode (%)

In operation

DataNode State: All

Show: 25 entries

Search:

Node	Http Address	Last contact	Last Block Report	Used	Non DFS Used	Capacity	Blocks	Block pool used	Version
✓(default-rack/datanode2-9866 (34.101.216.19:9866))	http://datanode2:9864	1s	25m	28 KB	5.16 GB	19.2 GB	0	28 KB (0%)	3.3.6
✓(default-rack/datanode1-9866 (34.50.105.102:9866))	http://datanode1:9864	1s	25m	28 KB	5.16 GB	19.2 GB	0	28 KB (0%)	3.3.6

Showing 1 to 2 of 2 entries

Previous


1

Next

Entering Maintenance

34.101.41.119:9870/dfshealth.html#tab-datanode

Bạn cũng có thể duyệt danh sách các file trong HDFS như sau:



Ngoài HDFS, bạn cũng có thể truy cập UI của Yarn (để chạy các chương trình MapReduce or Spark) tại: <http://<ip-namenode>:8088>

Phần 4: Thực hành sử dụng với HDFS và Yarn

4.1 Đẩy file dữ liệu vào HDFS

Trong phần này, chúng ta sẽ sinh ra một file dữ liệu txt, rồi đẩy file này vào cụm HDFS.

Bước 1: Login vào server **namenode**

sử dụng VSCode Remote Explorer với lệnh: `ssh root@<namenode-ip>`

Bước 2: Chuyển sang user hadoop, và setup các biến môi trường:

```
cd /home/hadoop
su hadoop
source /etc/profile.d/hadoop.sh
```

Bước 3: Clone github repo để download chương trình sinh dữ liệu:

```
git clone https://github.com/BKCLab/bigdata-learning.git
cd bigdata-learning/12/hadoop-cluster/app/generate-txt-file
npm install
```


Bước 4: Sinh file dữ liệu text với kích thước 100MB:

```
node main.js 100
```

Bước 5: Đẩy file vào HDFS

```
hdfs dfs -mkdir -p /user/hadoop/input  
hdfs dfs -put generated_lorem_ipsum.txt /user/hadoop/input/
```

Đến đây, bạn có thể kiểm tra file đã được đưa vào HDFS thông qua giao diện web:



4.2 Chạy chương trình xử lý dữ liệu trong HDFS

Bước 6: Chạy chương trình wordcount để đếm số từ xuất hiện trong file vừa sinh:

```
yarn jar  
$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.6.j  
ar wordcount /user/hadoop/input /user/hadoop/output
```

Sau khi chương trình chạy xong, terminal sẽ hiển thị:

```
Successfully created generated_lorem_ipsum.txt with approximately 100 MB of content.
hadoopnamenode:~/bigdata-learning/12/hadoop-cluster/app/generate-txt-files hdfs dfs -mkdir -p /user/hadoop/input
hadoopnamenode:~/bigdata-learning/12/hadoop-cluster/app/generate-txt-files hdfs dfs -put generated_lorem_ipsum.txt /user/hadoop/input/
hadoopnamenode:~/bigdata-learning/12/hadoop-cluster/app/generate-txt-files yarn jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.6.jar wordcount /user/hadoop/input /user/hadoop/output
2025-06-27 05:08:15,345 INFO client.DefaultHARFollowerProxyProvider: Connecting to ResourceManager at namenode/34.101.216.19:8032
2025-06-27 05:08:15,961 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/hadoop/.staging/job_1751000295001_0001
2025-06-27 05:08:16,414 INFO input.FileInputFormat: Total input files to process : 1
2025-06-27 05:08:16,525 INFO mapreduce.JobSubmitter: number of splits:1
2025-06-27 05:08:16,979 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1751000295001_0001
2025-06-27 05:08:16,979 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-06-27 05:08:17,221 INFO conf.Configuration: resource-types.xml not found
2025-06-27 05:08:17,222 INFO resource.ResourceUtilis: Unable to find 'resource-types.xml'.
2025-06-27 05:08:17,599 INFO impl.YarnClientImpl: Submitted application application_1751000295001_0001
2025-06-27 05:08:17,884 INFO mapreduce.Job: The url to track the job: http://namenode:8088/proxy/application_1751000295001_0001/
2025-06-27 05:08:17,886 INFO mapreduce.Job: Running job: job_1751000295001_0001
2025-06-27 05:08:27,046 INFO mapreduce.Job: Job job_1751000295001_0001 running in uber mode : false
2025-06-27 05:08:27,048 INFO mapreduce.Job: map 0% reduce 0%
2025-06-27 05:08:45,263 INFO mapreduce.Job: map 67% reduce 0%
2025-06-27 05:08:46,302 INFO mapreduce.Job: map 100% reduce 0%
2025-06-27 05:08:54,369 INFO mapreduce.Job: map 100% reduce 100%
2025-06-27 05:08:55,390 INFO mapreduce.Job: Job job_1751000295001_0001 completed successfully
2025-06-27 05:08:55,501 INFO mapreduce.Job: Counters: 54
File System Counters
  FILE: Number of bytes read=14412
  FILE: Number of bytes written=570321
  FILE: Number of read operations=0
  FILE: Number of large read operations=0
  FILE: Number of write operations=0
  HDFS: Number of bytes read=104859187
  HDFS: Number of bytes written=2458
  HDFS: Number of read operations=8
  HDFS: Number of large read operations=0
  HDFS: Number of write operations=2
  HDFS: Number of bytes read erasure-coded=0
Job Counters
  Launched map tasks=1
  Launched reduce tasks=1
  Data-local map tasks=1
  Total time spent by all maps in occupied slots (ms)=16821
  Total time spent by all reducers in occupied slots (ms)=5552
  Total time spent by all map tasks (ms)=16821
  Total time spent by all reduce tasks (ms)=5552
  Total vcore-milliseconds taken by all map tasks=16821
  Total vcore-milliseconds taken by all reduce tasks=5552
  Total megabyte-milliseconds taken by all map tasks=17224704
  Total megabyte-milliseconds taken by all reduce tasks=5685248
Map-Reduce Framework
  Map input records=15630
  Map output records=15620832
  Map output bytes=167343206
  Map output materialized bytes=2402
  Input split bytes=129
  Combine input records=15621757
  Combine output records=1110
  Reduce input groups=185
  Reduce shuffle bytes=2402
  Reduce input records=185
  Reduce output records=185
  Spilled Records=1295
  Shuffled Maps =1
  Failed Shuffles=0
  Merged Map outputs=1
  GC time elapsed (ms)=185
  CPU time spent (ms)=17670
  Physical memory (bytes) snapshot=624721920
  Virtual memory (bytes) snapshot=5463852288
  Total committed heap usage (bytes)=530579456
```

Khi này file kết quả sẽ được lưu ở /user/hadoop/output:

HadoopOverviewDatanodesDatanode Volume FailuresSnapshotStartup ProgressUtilities

Browse Directory

Couldn't preview the file. NetworkError: Failed to execute 'send' on 'XMLHttpRequest': Failed to load 'http://datanode2:9864/webhdfs/v1/user/hadoop/output/part-r-00000?op=OPEN&namenoderpcaddress=namenode:9000&offset=0&_=1751000779233'.

/user/hadoop/output

Go!

Show 25 entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	hadoop	supergroup	0 B	Jun 27 12:08	2	128 MB	_SUCCESS	
☐	-rw-r--r--	hadoop	supergroup	2.4 KB	Jun 27 12:08	2	128 MB	part-r-00000	

Showing 1 to 2 of 2 entries

Previous1Next

Hadoop, 2023.

Tuy nhiên, datanode của chúng ta sử dụng dns name, nên khi chưa cấu hình lại file /etc/hosts thì sẽ chưa xem được kết quả qua UI. Vì vậy, chúng ta sẽ sử dụng câu lệnh để xem kết quả như sau:

```
hdfs dfs -ls /user/hadoop/output
hdfs dfs -head /user/hadoop/output/part-r-00000
```

11 | Page

Phần 5: Kết thúc

Bước cuối: Sau khi thực hành xong, thực hiện lệnh sau để xoá các VM:

```
./destroy.sh
```