

Tài liệu hướng dẫn thực hành với Hadoop, Kafka, Spark

01/2026

Mục lục

Phần 1: Giới thiệu	1
1.1 Mục đích và ý nghĩa tài liệu.....	1
1.2 Yêu cầu chuẩn bị	1
Phần 2: Khởi tạo VM	2
Phần 3: L03 Spark WordCount	3

Phần 1: Giới thiệu

1.1 Mục đích và ý nghĩa tài liệu

Tài liệu này hướng dẫn người dùng cài đặt Hadoop, Yarn, Kafka, Spark, Nginx, Fluentbit lên VM của GCP, và thực hiện một số bài thực hành.

1.2 Yêu cầu chuẩn bị

- Một máy tính (Laptop, PC) có kết nối internet.
- Một tài khoản Google Cloud
- Ứng dụng VSCode

Phần 2: Khởi tạo VM

Tham khảo từ bài L01 tới trang 13, khởi tạo một VM với các thông số như sau:
E2, standard, 8vCPU, 32GB Ram, 50GB Disk, Ubuntu 24.04 LTS.

Sau khi khởi tạo thành công, tiến hành thiếp lập quyền truy cập vào root user, và truy cập VM bằng VSCode

	C3D	Consistently high performance	4 - 360	8 - 2,580 GB	AMD
☒	E2	Low cost, day-to-day computing	0.25 - 32	1 - 128 GB	Intel
☐	N2	Balanced price & performance	2 - 128	2 - 864 GB	Intel
☐	N2D	Balanced price & performance	2 - 224	2 - 896 GB	AMD
☐	T2A	Scale-out workloads	1 - 48	4 - 192 GB	Arm
☐	T2D	Scale-out workloads	1 - 60	4 - 240 GB	AMD
☐	N1	Balanced price & performance	0.25 - 96	0.6 - 624 GB	Intel

Machine type
Choose a machine type with preset amounts of vCPUs and memory that suit most workloads. Or, you can create a custom machine for your workload's particular needs. [Learn more](#)

Creating a custom machine incurs additional costs

Cores
2 32 vCPU
(4 core)

☐ Shared core

Memory
4 64 GB

Boot disk

Select an image or snapshot to create a boot disk; or attach an existing disk. Can't find what you're looking for? Explore hundreds of VM solutions in [Marketplace](#)

[Public images](#) [Custom images](#) [Snapshots](#) [Archive Snapshots](#)

Operating system

Version *
x86_64, amd64 noble image built on 2026-01-17

Boot disk type *

Size (GB) *
Provision between 10 and 65536 GB

Phần 3: L03 Spark WordCount

Mô tả: Trong phần này, chúng ta sẽ dựng cụm Hadoop để lưu các file text, sau đó dùng Spark để thực hiện xử lý đếm số lượng từ. Các chương trình của Spark có thể chạy trên nhiều loại cụm khác nhau như: cụm Spark, cụm Yarn, cụm K8S, Mesos. Trong bài này chúng ta sẽ sử dụng cụm Yarn để chạy cả Spark và MapReduce.

Bước 1: Cài đặt Docker:

```
cd /root
apt update
snap install docker
```

Bước 2: Clone code

```
git clone https://github.com/BKCLab/bigdata-learning.git
```

Dùng VSCode mở thư mục bigdata-learning/l3

Bước 3: Tạo network cho bài thực hành


```
docker network create bigdata-network
```

Bước 4: Chạy cụm Hadoop và Yarn

```
cd hadoop
docker compose up
```

Câu lệnh này sẽ tạo dựng một cụm hadoop gồm 1 namenode + 2 datanode, 1 yarn resource-manager và 2 node-manager, đồng thời compose cũng bao gồm 1 trình duyệt firefox – được sử dụng để dễ dàng truy cập tới các services trong cùng mạng.

Sau khi câu lệnh thực thi xong, truy cập địa chỉ: **http://<vm-ip>:5800** để mở firefox
Để truy cập vào UI của HDFS: gõ <http://namenode:9870> (có thể bạn cần phải tự gõ, vì firefox chạy trong container không hỗ trợ copy paste)



Truy cập Yarn tại: **http://<vm-ip>:8088**

Bước 5: Tạo file dữ liệu:

Di chuyển tới thư mục l3/hadoop/gen-data

Mở một terminal mới và download Nodejs:

```
curl -o- https://raw.githubusercontent.com/nvm-sh/nvm/v0.39.3/install.sh | bash
```

```
source ~/.bashrc
nvm install 20
node -v
```

Chạy lệnh sinh file dữ liệu:

```
npm i
node main 1024 input.txt
```

Trong đó:

1024 là kích thước file tính theo MB

input.txt là tên file

Thực hiện các lệnh sau để đưa dữ liệu vào hdfs:

```
docker compose exec -it namenode /bin/bash
hdfs dfs -mkdir -p /user/spark/input
hdfs dfs -put /opt/gen-data/input.txt /user/spark/input/
hdfs dfs -chmod -R 777 /
```

Bạn có thể kiểm tra kết quả và xem nội dung file bằng Hadoop UI:

Not Secure http://namenode:9870/explorer.html#/user/spark/input

Hadoop Overview Datanodes Datanode Volume Failures Snapshot Startup Progress Utilities

Browse Directory

/user/spark/input Go!

Show 25 entries Search:

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rwxrwxrwx	hadoop	supergroup	1 GB	Jan 22 06:43	1	128 MB	input.txt

Showing 1 to 1 of 1 entries Previous 1 Next

Hadoop, 2023.

Bước 6: Chạy Spark wordcount

Mở một terminal mới tại l3/hadoop:

```
docker compose exec spark-client \
/opt/spark/bin/spark-submit \
--master yarn \
--deploy-mode client \
--conf spark.yarn.resource.manager.hostname=resourcemanager \
--num-executors 4 \
--executor-cores 1 \
--executor-memory 2g \
/opt/spark-apps/simple_spark_app.py \
/user/spark/input/input.txt
```

Trong khi chương trình đang chạy, bạn có thể theo dõi tiến trình bằng Yarn UI hoặc terminal:

hadoop All Applications

Cluster Metrics

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Used Resources
3	0	1	2	1	<memory:1 GB, vCores:1>

Cluster Nodes Metrics

Active Nodes	Decommissioning Nodes	Decommissioned Nodes	Lost Nodes
2	0	0	0

Scheduler Metrics

Scheduler Type	Scheduling Resource Type	Minimum Allocation
Capacity Scheduler	[memory-mb (unit=M), vcores]	<memory:1024, vCores:1>

application_1769063730937_0003 spark SimpleSparkYARNApp SPARK default 0 Thu Jan 22 07:04:18 +0000 2026 Thu Jan 22 07:04:18 +0000 2026 Thu Jan 22 07:05:01 +0000 2026 FINISHED SUCCEEDED

hadoop MapReduce Job job_1769063730937_0004

Job Name: word count
User Name: hadoop
Queue Name: default
State: RUNNING
Uberized: false
Started: Thu Jan 22 07:08:46 UTC 2026
Elapsed: 46sec

ApplicationMaster

Attempt Number	Start Time	Node
1	Thu Jan 22 07:08:41 UTC 2026	5f43c48cc205:8042

Task Type	Progress	Total	Pending	Running
Map	8	0	8	0
Reduce	1	1	0	0

Attempt Type	New	Running	Failed	Killed
Maps	0	8	0	0
Reduces	1	0	0	0

```

20/01/22 07:03:01 INFO CODEC:
+-----+-----+
| word | count |
+-----+-----+
| Sit | 257325 |
| Elit | 257762 |
| consectetur. | 257866 |
| Officia | 257787 |
| veniam | 2062592 |
| Eu | 257119 |
| non. | 258177 |
| ipsum. | 257980 |
| tempor. | 258606 |
| Sunt | 258752 |
| Adipisicing | 258400 |
| cillum | 2063460 |
| dui. | 257487 |
| velit | 2062420 |
| laborum | 2063060 |
| fugiat | 2063724 |
| sunt. | 257441 |
| occaecat. | 257922 |
| non | 2064548 |
| adipisicing. | 258165 |
+-----+-----+
only showing top 20 rows

```

Bước 7: Thực hiện so sánh giữa MapReduce và Spark:

Thực hiện sinh các file dữ liệu với kích thước khác nhau, đưa các file này vào hdfs, rồi thực hiện chạy WordCount bằng MapReduce và Spark rồi so sánh thời gian thực thi.

(Bạn cũng có thể thử điều chỉnh các tham số của Spark như số lượng executor, tài nguyên cho mỗi executor, tham số shuffle.partitions v.v khi chạy Spark để so sánh kết quả)

Câu lệnh tham khảo để chạy Yarn WordCount:

```

docker compose exec -it namenode /bin/bash

yarn jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-
examples-3.3.6.jar wordcount /user/spark/input /user/spark/output

```