

Tài liệu hướng dẫn thực hành với Hadoop, Kafka, Spark

07/2025

Mục lục

Phần 1: Giới thiệu.....	1
1.1 Mục đích và ý nghĩa tài liệu.....	1
1.2 Yêu cầu chuẩn bị.....	1
Phần 2: Spark Streaming.....	2

Phần 1: Giới thiệu

1.1 Mục đích và ý nghĩa tài liệu

Tài liệu này hướng dẫn người dùng cài đặt Hadoop, Yarn, Kafka, Spark, Nginx, Fluentbit lên VM của GCP, và thực hiện một số bài thực hành.

1.2 Yêu cầu chuẩn bị

- Một máy tính (Laptop, PC) có kết nối internet.
- Một tài khoản Google Cloud
- Ứng dụng VSCode

Phần 2: Spark Streaming

Trong phần này, chúng ta sẽ làm quen với một data pipeline như sau:

1. Một Nginx web server thực hiện ghi log các requests ra file access.log
2. Fluentbit thực hiện fetch dữ liệu mới mỗi khi có request được log lại vào file access.log, và đẩy các bản ghi log này tới Kafka
3. Kafka được sử dụng làm message broker để làm đệm giữa Producer (Nginx+Fluentbit) và Consumer (Spark Streaming)
4. Spark Streaming: Thực hiện đọc dữ liệu từ Kafka và tiến hành các bước tính toán near real-time

Bước 1: Chạy Kafka

Di chuyển tới l3/kafka

Update file .env: IP_SERVER=<vm-ip>

Mở một terminal mới và chạy:

```
docker compose up -d
```


Chờ một ít phút, và truy cập Kafka UI tại: <http://kafka-ui:8080>

Bước 2: Chạy web server và fluentbit

Di chuyển tới l3/web và chạy câu lệnh:

```
docker compose up -d
```


Sau khi câu lệnh thực hiện xong, có thể gọi tới nginx tại: <http://web-server>
Đây là một web server đơn giản sẽ phản hồi lại path mà người dùng truy cập.



Bước 3: Thực hiện sinh giả lập các request tới web server:

```
./gen-requests.sh
```

Truy cập Kafka và kiểm tra nội dung các message:



Bước 4:

Chạy chương trình spark streaming phân tích dữ liệu các requests gửi tới nginx:

Di chuyển tới l3/hadoop:

Tạo thư mục log cho spark

```
docker compose exec -it namenode /bin/bash
```

```
hdfs dfs -mkdir /spark-logs
```

```
hdfs dfs -chmod -R 777 /
```

Sau khi thực hiện thành công, gõ “exit” và thực hiện câu lệnh sau:

```
docker compose exec spark-client spark-submit \
  --packages org.apache.spark:spark-sql-kafka-0-10_2.12:3.5.0 \
  --master yarn \
  --deploy-mode client \
  --conf spark.yarn.resource.manager.hostname=resourcemanager \
  --conf spark.eventLog.enabled=true \
  --conf spark.eventLog.dir=hdfs:///spark-logs \
  --conf spark.history.fs.logDirectory=hdfs:///spark-logs \
  --conf spark.sql.adaptive.enabled=true \
  --conf spark.sql.adaptive.coalescePartitions.enabled=true \
```

```
--conf spark.streaming.backpressure.enabled=true \  
--conf spark.sql.shuffle.partitions=24 \  
/opt/spark-apps/nginx_log_analyzer.py
```

Bước 5:

Kết thúc bài thực hành bằng việc:

- Xóa Virtual Machine: Compute Engine => Virtual machines => VM instances
- Xóa Project: IAM & Admin => Settings => chọn Project => Shutdown
- Xóa thanh toán: Billing management => Account management => Actions: chọn Disable